

Projet M1 : 'Classification supervisée ouverte et découverte de nouvelles catégories'

</> Code

tags: [Projet](#) [Master](#) [Sciences participatives](#) [découverte de catégories](#) [algorithme Kmeans](#) [algorithme hongrois](#) [Matrices de confusion](#)

Nom des encadrants

- Joseph Salmon (Inria)
- Hervé Goëau (Cirad)
- Pierre Bonnet (Cirad)

Contexte et Motivation

Les plateformes de sciences participatives comme **Pl@ntNet** permettent à des milliers de citoyens d'identifier des espèces végétales via des photographies. Pourtant, un défi persiste : malgré la découverte annuelle de milliers de nouvelles espèces, beaucoup restent inconnues ou mal identifiées.

Ces découvertes sont essentielles pour affiner les inventaires écologiques, protéger les espèces rares avant leur disparition et améliorer la qualité des bases de données, réduisant ainsi les erreurs d'identification qui peuvent biaiser les analyses.

Dans ce projet, nous proposons d'aborder ce défi en utilisant des outils d'apprentissage automatique et de statistique pour améliorer les performances des systèmes d'identification participative comme **Pl@ntNet**.

Classiquement, ces systèmes reposent sur la **classification supervisée** : les images collectées en phase d'apprentissage sont annotées par des experts ou des contributeurs, et leurs catégories forment un ensemble fini et prédéfini, représentant l'espace des espèces connues ou observables. Cependant, nous cherchons ici à dépasser ce cadre pour considérer un contexte **"ouvert"**, où les étiquettes possibles ne sont que partiellement connues lors de l'entraînement, permettant l'ajout de nouvelles espèces par la suite.

Cadre de la classification supervisée (fermée)

En classification supervisée, on modélise généralement les données images/étiquettes à l'aide des notations suivantes :

- Soit $\mathcal{X}$ l'espace de représentation des images.
- Soit $\mathcal{Y} = \llbracket 1, K \rrbracket$ l'espace des étiquettes (ici les espèces de plantes), où $\mathcal{Y}$ est l'ensemble fini des K catégories possibles.

Données d'entraînement : On dispose de n_{train} observations étiquetées, notées

$$(x_i, y_i) \in \mathcal{X} \times \mathcal{Y}, \quad \text{pour } i \in I_{train},$$

avec $|I_{train}| = n_{train}$.

Objectif : L'objectif est d'entraîner (sur les données d'entraînement) un classifieur $\hat{f}$ capable de

prédire, pour chaque nouvelle observation x_i , une estimation $\hat{y}_i = \hat{f}(x_i)$ de la vraie étiquette non observée $y_i \in \mathcal{Y}$. Le but est de minimiser l'erreur de prédiction afin d'améliorer la précision du modèle.

Cadre de la classification supervisée ouverte

En classification supervisée ouverte, on considère un espace d'étiquettes potentiellement plus large que celui observé fourni par les annotateurs. De plus, ici on s'intéresse au cas où l'on dispose de données non-annotées pour lesquelles il y a sans doute des étiquettes inconnues¹.

Données d'entraînement

- **Données étiquetées** : On dispose d'un ensemble d'indices $I_{train}^{\mathcal{L}}$ pour les observations **étiquetées** ( *labelled*), associées à un ensemble d'étiquettes connues $\mathcal{Y}_{\mathcal{L}} = \llbracket 1, K_{\mathcal{L}} \rrbracket$:

$$(x_i, y_i) \in \mathcal{X} \times \mathcal{Y}_{\mathcal{L}}, \quad \text{pour } i \in I_{train}^{\mathcal{L}}.$$

- **Données non étiquetées** : On dispose également d'un ensemble d'observations non-étiquetées, indexées par $I_{train}^{\mathcal{U}}$, dont les étiquettes appartiennent à un ensemble (de taille potentiellement inconnue) $\mathcal{Y}_{\mathcal{U}} = \llbracket 1, K_{\mathcal{U}} \rrbracket$:

$$x_i \in \mathcal{X}, \quad \text{pour } i \in I_{train}^{\mathcal{U}}.$$

On suppose que $\mathcal{Y}_{\mathcal{L}} \subseteq \mathcal{Y}_{\mathcal{U}}$ (donc $K_{\mathcal{L}} \leq K_{\mathcal{U}}$), c'est-à-dire que l'ensemble des catégories connues est un sous-ensemble des catégories potentielles. Lors de la phase d'entraînement, on observe les n_{train} observations indexées par $I_{train} = I_{train}^{\mathcal{L}} \cup I_{train}^{\mathcal{U}}$, mais les étiquettes ne sont connues que pour les observations indexées par $I_{train}^{\mathcal{L}}$.

Objectif principal : En **classification ouverte**, l'objectif est de pouvoir prédire une étiquette pour une nouvelle observation, qui peut appartenir soit à l'ensemble des catégories **connues** ($\mathcal{Y}_{\mathcal{L}}$), soit à l'ensemble des catégories **inconnues** ($\mathcal{Y}_{\mathcal{U}} \setminus \mathcal{Y}_{\mathcal{L}}$).

Objectifs du projet

Ce projet a pour objectif d'évaluer la faisabilité et l'efficacité de méthodes d'apprentissage supervisée ouverte. En particulier, on se familiarisera avec l'algorithme de partitionnement **KMeans** appliqué à des **données simulées** (représentant des observations végétales). L'idée centrale est d'explorer comment une approche de regroupement ( *clustering*) peut contribuer à l'identification d'espèces inconnues.

Approche proposée

L'approche proposée se décompose en plusieurs phases. Dans un premier temps, on propose d'estimer le nombre d'espèces inconnues. Cela se base sur l'algorithme de partitionnement KMeans, appliqué à l'ensemble des données de I_{train} , et l'on optimise le nombre de participation pour obtenir la meilleur exactitude de classification sur la partie $I_{train}^{\mathcal{L}}$. Une fois ce nombre évalué, on va utiliser une variante de KMeans semi-supervisé pour améliorer le le partitionnement des données, et enfin la reconnaissance des classes de $\mathcal{Y}$.

impose la reconnaissance des classes de $\mathcal{Y}_U$.

Rappel sur KMeans

Pour cette partie on commence par rappeler l'algorithme KMeans qui permet de partitionner les données.

Algorithm 1 KMeans

Input: Set of data points $\{x_1, \dots, x_N\} \subset (\mathbb{R}^d)^N$, number of clusters K , initial centroids μ_h

- 1: **while** not converged **do**
 - 2: Assign each data point $x \in \{x_1, \dots, x_N\}$ to the cluster h^* (i.e. set $\mathcal{X}_{h^*}$), for $h^* = \arg \min_{h=1, \dots, K} \|x - \mu_h\|^2$
 - 3: $\mu_h \leftarrow \frac{1}{|\mathcal{X}_h|} \sum_{x \in \mathcal{X}_h} x$
 - 4: **end while**
 - 5: **return** $\{\mathcal{X}_l\}_{l=1}^K$, K -Partition of $\mathcal{X}$.
-

Une fois les centroïdes $\{\mu_1, \dots, \mu_K\}$ estimés, on définit une fonction d'affectation $\hat{f} : \mathcal{X} \rightarrow \llbracket 1, K \rrbracket$ qui associe chaque nouvelle observation $x \in \mathcal{X}$ au cluster dont le centroïde est le plus proche. Formellement, cette fonction est définie par :

$$\hat{f}(x) = \arg \min_{h=1, \dots, K} \|x - \mu_h\|^2,$$

où $\|x - \mu_h\|^2$ est la distance euclidienne au carré entre l'observation x et le centroïde μ_h du cluster h .

Dans la suite, nous considérons que l'argument d'initialisation (généralement réalisé avec K-Means++, ou par une assignation aléatoire parmi les observations à partitionner) est optionnel. Ainsi, nous notons $\text{KMeans}(\{x_1, \dots, x_N\}, K)$ l'application de l'algorithme K-Means à la base de données $\{x_1, \dots, x_N\}$ pour un nombre de partitions K .

Par abus de notation, nous désignerons également par $\hat{f} = \text{KMeans}(\{x_1, \dots, x_N\}, K)$ la fonction d'affectation obtenue après l'entraînement de l'algorithme K-Means sur les données $\{x_1, \dots, x_N\}$ (analogue à la méthode `fit` de `sklearn.cluster.KMeans`). Cette fonction $\hat{f}$ permet ainsi de partitionner l'espace $\mathcal{X}$ en K clusters distincts.

Estimation du nombre total d'espèces

Pour parvenir à une estimation du nombre total d'espèces, on va faire varier k (qui sera alors $k = |\mathcal{Y}_U|$) et choisir la valeur qui maximise l'exactitude de la méthode KMeans sur l'ensemble des données étiquetées (indexées par I_{train}^U). Plus précisément, décrivons les deux points importants:

1. **Évaluation de l'exactitude** : Pour chaque k dans l'intervalle $\llbracket k_{min}, k_{max} \rrbracket$, effectue une partition des données (étiquetées et non-étiquetées) $\{x_i\}_{i \in I_{train}}$ avec KMeans. Ainsi, on évalue $\hat{f}_k = \text{KMeans}(\{x_i\}_{i \in I_{train}}, k)$, ce qui revient à supposer que le nombre de classes total (inconnu) est $K_U = k$. L'exactitude ( *accuracy*) du classifieur est calculée sur la partie annotée indexée par I_{train}^L :

$$\text{ACC}(k) = \max_{\sigma \in \mathfrak{S}_k} \frac{1}{|I_{train}^L|} \sum_{i \in I_{train}^L} \mathbb{1} \left\{ y_i = \sigma \left(\hat{f}_k(x_i) \right) \right\} \quad , \quad (1)$$

où $\mathfrak{S}_k$ est l'ensemble de toutes les permutations possibles de $\llbracket 1, k \rrbracket$. Cette métrique évalue la **correspondance optimale** entre les clusters obtenus et les étiquettes connues, en intégrant explicitement l'invariance des partitions par permutation des étiquettes de clusters (une propriété intrinsèque des algorithmes de partitionnement). Le problème d'affectation sous-jacent, formulé dans l'[Equation 1](#), est résolu efficacement par l'**algorithme hongrois**².

2. **Optimisation du nombre de clusters** : Pour estimer le nombre de classes inconnues, nous résolvons le problème d'optimisation discret suivant, visant à identifier le paramètre k (nombre de classes inconnues) qui maximise la correspondance optimale entre clusters et étiquettes connues :

$$\hat{k} = \arg \max_{k \in [k_{\min}, k_{\max}]} \text{ACC}(k).$$

Pour ce faire, nous employons l'**algorithme de Brent** (disponible via `scipy.optimize.minimize_scalar`), une méthode robuste et efficace pour déterminer le nombre optimal de clusters $\hat{k}$ maximisant l'exactitude de classification. Cette approche garantit une recherche précise dans l'intervalle discret défini.

Attribution d'étiquettes avec KMeans semi-supervisé

Une fois $\hat{k}$ obtenu, on va raffiner le partitionnement. On applique un algorithme de type **KMeans**³ avec ce choix de $\hat{k}$ à l'ensemble des observations d'entraînement indexées par $I_{train} = I_{train}^{\mathcal{L}} \cup I_{train}^{\mathcal{U}}$. En plus de l'algorithme KMeans classique on comparera des variantes semi-supervisées suivantes incluant :

- Seeded-Kmeans par Basu et al. (2002), voir [Algorithm 3](#)
- une combinaison de Constrained-Kmeans avec une initialization par kmeans++⁴, voir [Algorithm 4](#).

Algorithm 2 KMeans++

Input: Set of data points $\{x_1, \dots, x_N\} \subset (\mathbb{R}^d)^N$, number of clusters K

- 1: Choose the first centroid μ_1 uniformly at random from $\{x_1, \dots, x_N\}$
 - 2: Initialize the set of centroids $\mathcal{C} \leftarrow \{\mu_1\}$
 - 3: **for** $h = 2$ to K **do**
 - 4: Compute the squared distances $D(x)^2 = \min_{\mu \in \mathcal{C}} \|x - \mu\|^2$ for each $x \in \{x_1, \dots, x_N\}$
 - 5: Choose the next centroid μ_h with probability $\frac{D(x)^2}{\sum_{x'} D(x')^2}$
 - 6: Update the set of centroids $\mathcal{C} \leftarrow \mathcal{C} \cup \{\mu_h\}$
 - 7: **end for**
 - 8: **return** Initial centroids $\mathcal{C} = \{\mu_1, \dots, \mu_K\}$
-

Algorithm 3 Seeded-KMeans++ Init

Require: Set of data points $\mathcal{X} = \{x_1, \dots, x_N\} \subset (\mathbb{R}^d)^N$, number of clusters K , seed set $\mathcal{S} = \bigcup_{l=1}^{K'} \mathcal{S}_l \subset \mathcal{X}$ with $K' \leq K$, where each $\mathcal{S}_l$ contains seed points assigned to cluster l by user supervision

- 1: Initialize centroids $\mu_l \leftarrow \frac{1}{|\mathcal{S}_l|} \sum_{x \in \mathcal{S}_l} x$, for $l = 1, \dots, K'$
 - 2: Initialize the set of centroids $\mathcal{C} \leftarrow \{\mu_1, \dots, \mu_{K'}\}$
 - 3: **for** $h = K' + 1$ to K **do**
 - 4: Compute the squared distances $D(x)^2 = \min_{\mu \in \mathcal{C}} \|x - \mu\|^2$ for each $x \in \mathcal{X}$
 - 5: Choose the next centroid μ_h with probability $\frac{D(x)^2}{\sum_{x' \in \mathcal{X}} D(x')^2}$
 - 6: Update the set of centroids $\mathcal{C} \leftarrow \mathcal{C} \cup \{\mu_h\}$
-

```
7: end for
8: return Initial centroids  $\mathcal{C} = \{\mu_1, \dots, \mu_K\}$ 
```

Algorithm 4 Constrained-KMeans with Seeded-KMeans++ Init

Input: Set of data points $\{x_1, \dots, x_N\} \subset (\mathbb{R}^d)^N$, number of clusters K , seed set $\mathcal{S} = \bigcup_{l=1}^{K'} \mathcal{S}_l \subset \{x_1, \dots, x_N\}$ with $K' \leq K$, where each $\mathcal{S}_l$ contains seed points assigned to cluster l by user supervision

```
1: Initialize centroids  $\mathcal{C} \leftarrow \text{Seeded-KMeans}++\text{-Init}(\{x_1, \dots, x_N\}, K, \mathcal{S})$ 
2: while not converged do
3:   for  $l = 1$  to  $K'$  do
4:     For  $x \in \mathcal{S}_l$ , assign  $x$  to the cluster  $l$  (i.e., set  $\mathcal{X}_l$ )
5:   end for
6:   for  $x \in \{x_1, \dots, x_N\} \setminus \mathcal{S}$  do
7:     Assign  $x$  to the cluster  $h^*$  (i.e., set  $\mathcal{X}_{h^*}$ ), for  $h^* = \arg \min_{h=1, \dots, K} \|x - \mu_h\|^2$ 
8:   end for
9:    $\mu_h \leftarrow \frac{1}{|\mathcal{X}_h|} \sum_{x \in \mathcal{X}_h} x$ , for  $h = 1, \dots, K$ 
10: end while
11: return  $\{\mathcal{X}_l\}_{l=1}^K, K\text{-Partition of } \{x_1, \dots, x_N\}$ 
```

Évaluation des performances

Pour évaluer rigoureusement les procédures proposées, une analyse des performances est menée sur des jeux de données de test, couvrant à la fois des scénarios simplifiés et des conditions réalistes.

Simulations

1. Scénario simplifié :

- Données simulées: Clusters gaussiens bien séparés, avec un faible taux de confusion.
- Objectif: Valider le comportement de l'algorithme dans un cadre idéalisé, où les structures de données sont claires et les ambiguïtés minimales.

2. Scénario avancé (semi-synthétique) :

- Données semi-synthétiques : Clusters reproduisant les confusions observées dans les données réelles, en exploitant les matrices de confusion empiriques pour les orchidées européennes (~130 espèces).
- **Source des matrices** : Données issues d'annotations d'experts, capturant les confusions réalistes entre espèces morphologiquement proches.
- **Objectif** : Évaluer la robustesse de l'algorithme face à des ambiguïtés typiques des données du monde réel, en particulier pour des espèces difficiles à distinguer.

Encadrement et Ressources

- **Encadrement** : Le projet sera co-encadré par des chercheurs en écologie et en sciences des données.
- **Ressources** :
 - Environnement de développement (Python).
 - Soutien méthodologique pour les simulations et l'analyse statistique.
 - Accès à des jeux de données de PI@ntNet, selon progression.

Références

1. Sagar Vaze, Kai Han, Andrea Vedaldi and Andrew Zisserman, *Generalized Category Discovery*, In CVPR, 2022. [url](#)
2. Basu, S., Banerjee, A., & Mooney, R. J. *Semi-supervised clustering by seeding*. In ICML, 2002. [url](#)

Footnotes

1. Pour info dans Pl@ntNet on compte de l'ordre de 10 millions d'images annotées, mais il y a plus d'1.5 milliards d'image stockées! [↩](#)
2. https://fr.wikipedia.org/wiki/Algorithme_hongrois [↩](#)
3. On utilisera la version par défaut, mais aussi une version semi-supervisée qui force les observations indexées par $I_{train}^{\mathcal{L}}$ (c'est-à-dire les images étiquetées) à appartenir au même cluster que leur étiquette connue. [↩](#)
4. voir détails d'implémentation [documentation de sklearn](#) ou [wikipedia](#) [↩](#)